ECT_HW3 2020

第一大題

第一大題

用Weka軟體對BreastCancerNUM.arff, BreastCancerNOM.arff 分別建立Linear Regression model及Logistic model, 選擇 "Use training set", 設定Attribute: type為diagnosis, 在過程中對重要步驟截圖加以說明, 並回答以下問題:

第一大題(a)-題目

(a) LinearRegression model中,多少因素與乳癌為正相關?多少為負相關? (10%)

第一大題(a)-解答

```
-0.0709 * radius mean +
-0.0047 * perimeter_mean +
 0.0008 * area_mean +
 3.8735 * compactness_mean +
-1.1601 * concavity_mean +
-1.9936 * concave points_mean +
-0.969 * radius_se +
 0.0363 * perimeter se +
 0.0029 * area_se +
-19.4375 * smoothness_se +
 3.0168 * concavity se +
-0.0105 * texture_worst +
-0.0058 * perimeter_worst +
 0.0002 * area worst +
-0.3631 * concavity_worst +
-1.8387 * concave points_worst +
-0.811 * symmetry_worst +
-3.909 * fractal_dimension_worst +
 3.133
```

diagnosis =

正相關:6

負相關:12

第一大題(b)-題目

(b) 舉出三個LinearRegression model認為與乳癌無關的因素 (10%)

第一大題(b)-解答

自由作答,三個未出現在function中的Attribute即可

第一大題(c)-題目

(c) 比較Logistic model與Linear Regression model的均方根誤

差,兩者差距多少?哪個模型表現較好? (30%)

第一大題(c)-解答

Logistic

Correctly Classified Instances	569	100	96
Incorrectly Classified Instances	0	0	ele ele
Kappa statistic	1		
Mean absolute error	0		
Root mean squared error	0.0003		
Relative absolute error	0.0085 %		
Root relative squared error	0.0538 %		
Total Number of Instances	569		

Linear

Correlation coefficient	0.8761
COTTETACTOR COEFFICIENT	0.0761
Mean absolute error	0.1841
Root mean squared error	0.2331
Relative absolute error	39.3731 %
Root relative squared error	48.2196 %
Total Number of Instances	569

差距0.2331-0.0003=0.2328 Logistic表現較好

第二大題

第二大題

用python對BreastCancer.csv建立LinearRegression model及 Logistic model, 在過程中對重要步驟截圖加以說明,並回答以下問 題:

logistic_reg.fit(x, y.values.ravel())

第二大題(a)-題目

(a) 以coef_function印出各Attribute的相關係數, 請問 LinearRegression model中, Attribute 'area_mean'的係數是多少?(10%)

第二大題(a)-解答

第二大題(b)-題目

(b) LinearRegression model中,影響最大的因素為何?(20%)

第二大題(b)-解答

• 取絕對值最大:smoothness_se

```
array([[ 2.17772056e-01, -4.54546867e-03, -2.37398610e-02, -3.17834750e-04, -8.46891371e-02, 4.22203525e+00, -1.39799728e+00, -2.14183303e+00, -1.02709200e-01, -3.32616096e-02, -4.34955932e-01, 6.75847233e-03, 2.25202577e-02, 9.23217886e-04, -1.58543207e+01, -6.49034090e-02, 3.56546799e+00, -1.05679513e+01, -1.69734069e+00, 7.14644016e+00, -1.95183121e-01, -7.15937520e-03, 2.43505057e-03, 1.01122332e-03, -5.42856861e-01, -6.71582941e-02, -3.81191215e-01, -4.64309895e-01, -5.56787546e-01, -4.30348309e+00]])
```

第二大題(c)-題目

(c) 以score() function印出兩模型的正確率,請問何者較高?(20%)

第二大題(c)-解答

LinearRegression

reg.score(x, y)

0.7743246526421793

LogisticRegression

logistic_regr.score(x, y)

0.9595782073813708

Logistic較高