SVM 支援向量機

NCU MIS 106403551 呂晟維

1. 使用 weka 對 heart.arff 進行SVM分析，過程中對所有重要步驟進行截圖並加以說明，越詳盡好：
   - (a) 請嘗試修改 heart.arff，使其可以使用 SMO function 進行 SVM 分析，並說明原本為何無法使用 SMO (5%)
   - (b) 請嘗試去除有空值的資料 (5%)
   - (c) 用SMO function 對前處理過的 heart.arff 進行 SVM 分析，kernel 設為'linear'，Percentage spilt 設為 66%，截圖並附上過程及準確率 (30%)
2. 使用 python 依照步驟對 heart.csv 進行 SVM 分析，過程中對所有重要程式步驟進行截圖並加以說明，越詳盡越好：
   - (d) 請問資料集是否有空值 ?有幾筆資料含有空值 ?如有空值即去掉該筆資料 (5%)
   - (e) 將最後一個屬性值 ”target” 切分成 Label，其餘屬型切分為 Feature (5%)
   - (f) 將 Feature 用 sklearn.preprocessing 的 StandardScaler 進行標準化 (10%)
   - (g) 切分資料集與測試集，設 test_size=0.33，random_state=1 (10%)
   - (h) 最後，使用 sklearn.svm 裡的 SVC 進行分析，kernel 設為'linear'，並印出模型最終的準確度 (30%)

Weka部分

(a) 請嘗試修改 heart.arff，使其可以使用 SMO function 進行 SVM 分析，並說明原本為何無法使用 SMO (5%)

可以觀察到原本的.arff有空值，也都是Numeric型態的數值資料，Weka無法執行的主要原因是SVM是Binary Classifier，需要將Label也就是 `target` 欄位轉成Nominal型態。所以將.arff的 `target` 欄位稍作修改成下方樣式就可以執行了。

```
@attribute target {0, 1}
```

這裡我另外save為 `heart_Nom.arff` 。

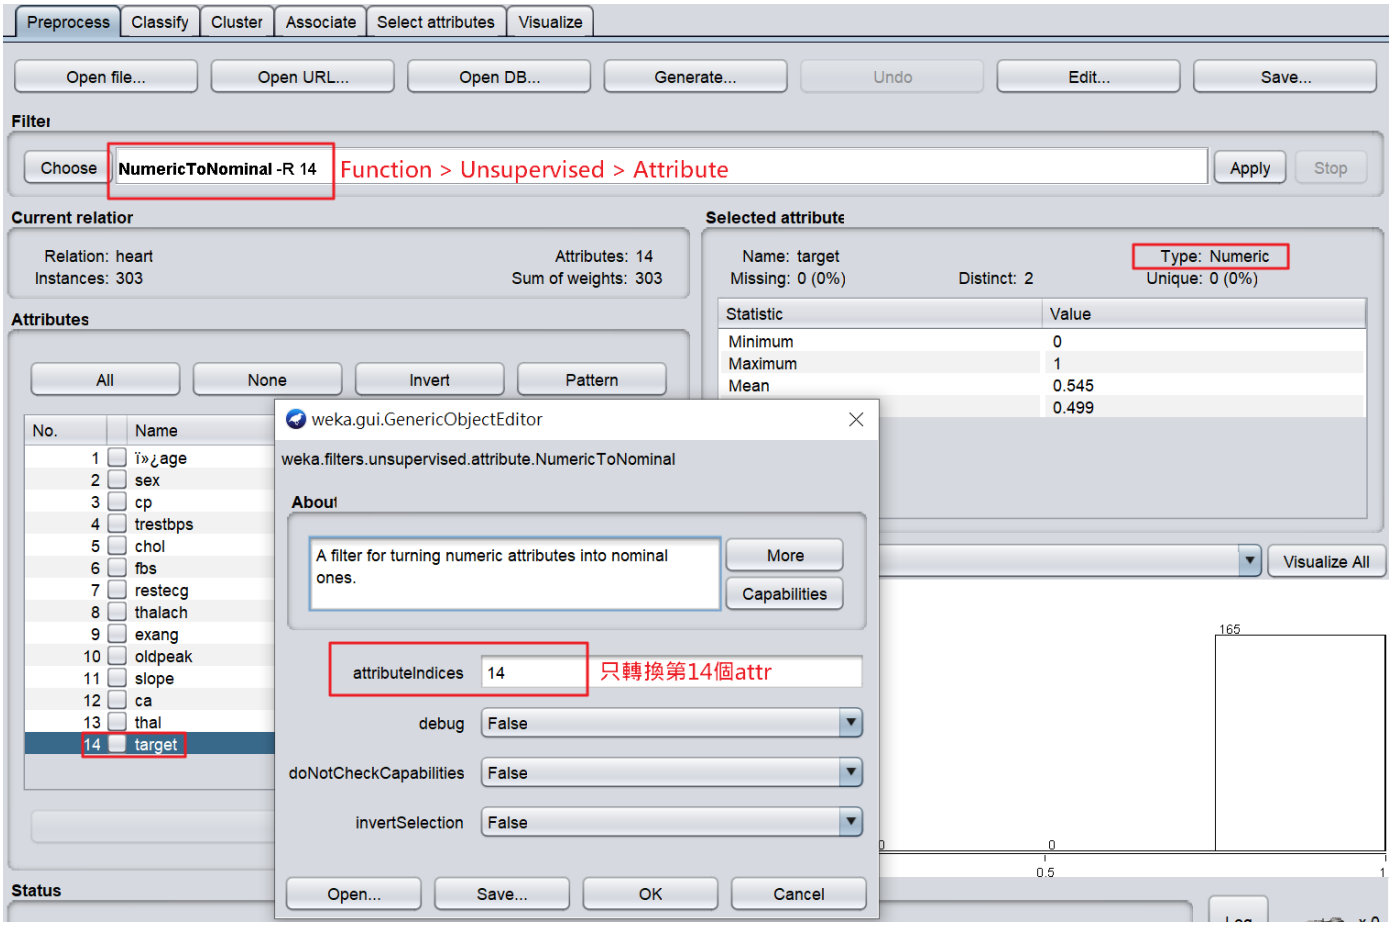

(b) 請嘗試去除有空值的資料 (5%)

由於原本的.arff有空值，我們使用weka內建的editor來手動刪除有空值的資料列，選取時同時按住 `ctrl` 鍵可以同時選取多筆資料再一次刪除，這裡我另外save為 `heart_rmNull.arff` 。

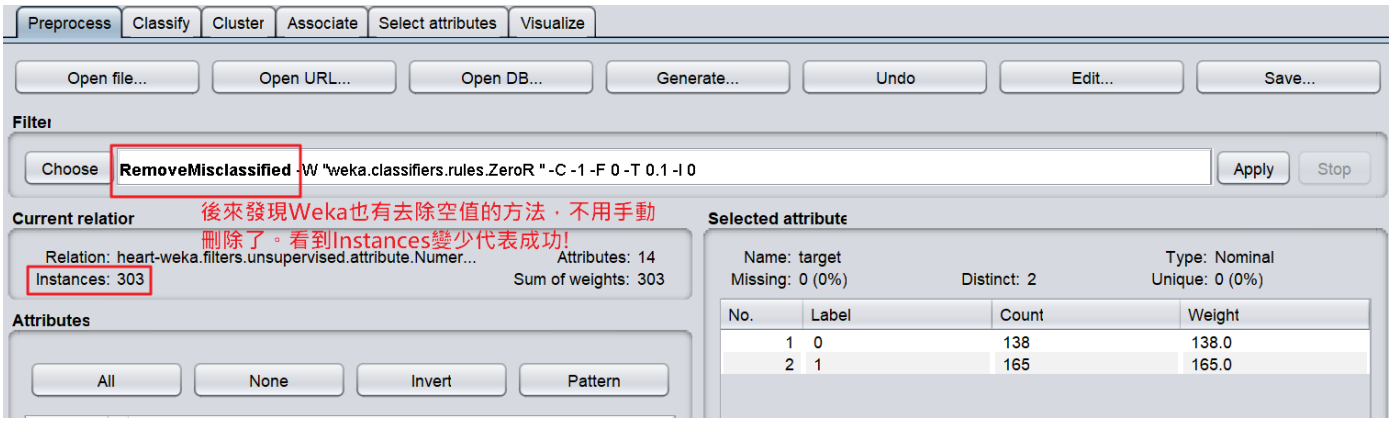

(c) 用 SMO function 對前處理過的 heart.arff 進行 SVM 分析，kernel 設為'linear'，Percentage spilt 設為 66%，截圖並附上過程及準確率 (30%)

SVM方法在Weka中稱作SMO，SVM最精華的地方在於Kernel function，我們這次要求做linear的Kernel function，因此選擇多項式的PolyKernal，把次方數設為1表示線性SVM。調整完後按下確定執行就可以囉!

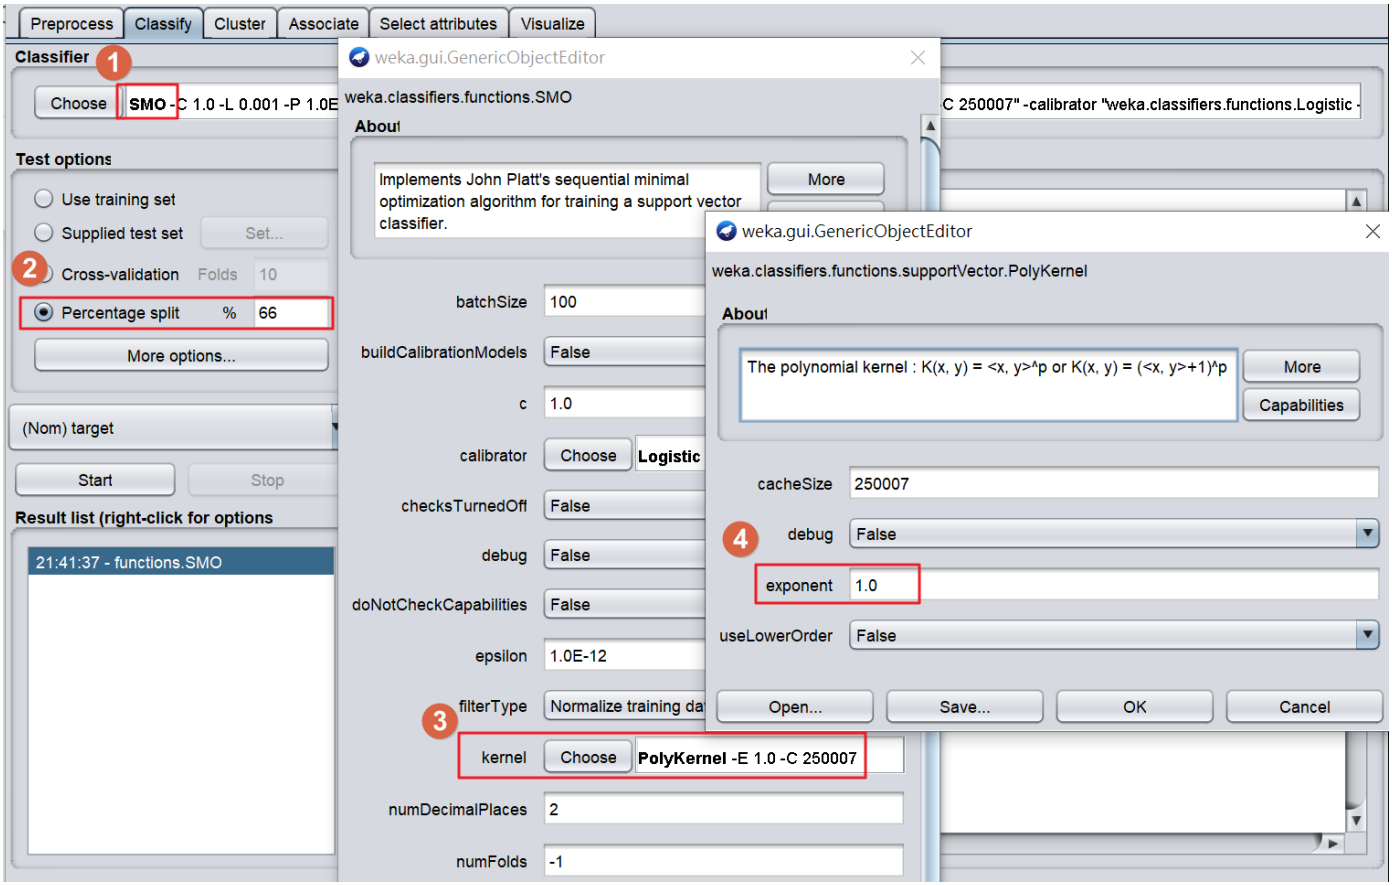

執行結果的 `Classifier model` 如下，可以看到我們的Kernel是 `Linear Kernel: K(x,y) = <x,y>` ，代表線性回歸，沒有把資料投射到更高維度的空間中。

```
=== Classifier model (full training set) ===

SMO

Kernel used:
  Linear Kernel: K(x,y) = <x,y>

Classifier for classes: 0, 1

BinarySMO

Machine linear: showing attribute weights, not support vectors.

        -0.3014 * (normalized) ï»¿age
 +      -1.0026 * (normalized) sex
 +       1.734  * (normalized) cp
 +      -0.9088 * (normalized) trestbps
 +      -0.4322 * (normalized) chol
 +       0.0432 * (normalized) fbs
 +       0.2627 * (normalized) restecg
 +       1.2303 * (normalized) thalach
 +      -0.769  * (normalized) exang
 +      -1.7558 * (normalized) oldpeak
 +       0.7044 * (normalized) slope
 +      -1.6552 * (normalized) ca
 +      -1.6355 * (normalized) thal
 +       1.7718

Number of kernel evaluations: 13465 (77.441% cached)
```

然後我們的準確率是86%，如果Kernel選擇更高次方可提升準確率，但怕有overfit的現象。

```
=== Summary ===

Correctly Classified Instances          86               86      %
Incorrectly Classified Instances        14               14      %
Kappa statistic                          0.72
Mean absolute error                      0.14
Root mean squared error                  0.3742
Relative absolute error                 28      %
Root relative squared error             74.2256 %
Total Number of Instances              100
```

Python部分

詳細的程式碼和參考資料等解說還是寫放在 SVM - Heart Attack.ipynb 裡。

(d) 請問資料集是否有空值 ?有幾筆資料含有空值 ?如有空值即去掉該筆資料 (5%)

將csv資料讀入成 df 後，我們檢查是否有空值並確認有10筆空資料。

```
>>> df.isnull().values.any()

True
```

```
>>> df.isnull().sum()

age         0
sex         0
cp          1
trestbps    0
chol        2
fbs         0
restecg     3
thalach     0
exang       1
oldpeak     2
slope       1
ca          0
thal        0
target      0
dtype: int64
```

刪除有空值的資料，資料筆數從303改為293。

```
df.dropna(axis=0, inplace=True)
```

(e) 將最後一個屬性值 "target" 切分成 Label，其餘屬型切分為 Feature (5%)

- label 變數是target欄位的資料，是資料集的output
- features 變數資料集的14欄input

```
features = df.iloc[:, 0:13]
label = df['target']
```

(f) 將 Feature 用 sklearn.preprocessing 的 StandardScaler 進行標準化 (10%)

由於 SVM 的資料需要標準化。用 sklearn.preprocessing 的 StandardScaler 進行特徵標準化。

```
>>> from sklearn.preprocessing import StandardScaler
>>> scaler = StandardScaler().fit(features)

StandardScaler(copy=True, with_mean=True, with_std=True)
```

After fitting, Mean and standard deviation are then stored to be used on later data using transform.

```
>>> scaler.transform(features)

array([[ 0.96008384,  0.68190908,  1.97865831, ..., -2.26047188,
```

```
        -0.71658705, -2.12994828],
       [-1.90587175,  0.68190908,  1.00592864, ..., -2.26047188,
        -0.71658705, -0.50051004],
       [-1.46495551, -1.46647115,  0.03319897, ...,  0.9703489 ,
        -0.71658705, -0.50051004],
       ...,
       [ 1.51122914,  0.68190908, -0.93953071, ..., -0.64506149,
         1.23652928,  1.1289282 ],
       [ 0.29870947,  0.68190908, -0.93953071, ..., -0.64506149,
         0.25997112,  1.1289282 ],
       [ 0.29870947, -1.46647115,  0.03319897, ..., -0.64506149,
         0.25997112, -0.50051004]])
```

(g) 切分資料集與測試集，設 test_size=0.33，random_state=1 (10%)

切分資料集與測試集，設 test_size=0.33, random_state=1

train_size：三种类型。float，int，None。

- float：0.0-1.0之间，代表训练数据集占总数据集的比例。
- int：代表训练数据集具体的样本数量。
- None：设置为test_size的补。
- default：默认为None。

random_state：三种类型。int，randomstate instance，None。

- int：是随机数生成器的种子。每次分配的数据相同。
- randomstate：random_state是随机数生成器的种子。（这里没太理解）
- None：随机数生成器是使用了np.random的randomstate。
- 种子相同，产生的随机数就相同。种子不同，即使是不同的实例，产生的种子也不相同。

```
>>> import numpy as np
>>> from sklearn.model_selection import train_test_split

>>> X_train, X_test, y_train, y_test = train_test_split(features, label, test_size=0.33,
random_state=1)
```

(h) 最後，使用 sklearn.svm 裡的 SVC 進行分析，kernel 設為'linear'，並印出模型最終的準確度 (30%)

這裡用Score方法和Classification Report來得出模型的準確度，都有80多%的準確率。如果kernel設高次方應該可以再提升準確率。

```
>>> from sklearn import svm

>>> linear_svc = svm.SVC(kernel='linear').fit(X_train, y_train)
>>> linear_svc

SVC(C=1.0, cache_size=200, class_weight=None, coef0=0.0,
    decision_function_shape='ovr', degree=3, gamma='auto_deprecated',
    kernel='linear', max_iter=-1, probability=False, random_state=None,
    shrinking=True, tol=0.001, verbose=False)
```

Accurecy in Training set

```
>>> linear_svc.score(X_train, y_train)

0.8367346938775511
```

Accurecy in Testing set

```
>>> linear_svc.score(X_test, y_test)

0.865979381443299
```

Classification Report

```
>>> expected = y_test
>>> predicted = linear_svc.predict(X_test)

>>> from sklearn import metrics
>>> print(metrics.classification_report(expected, predicted))

             precision    recall  f1-score   support

          0       0.90      0.81      0.85        47
          1       0.84      0.92      0.88        50

avg / total       0.87      0.87      0.87        97
```

在繳交程式碼檔案裡，我還有視覺化confusion matrix。 d(d’∀’).